

فاز اول: آماده سازی داده ها و تحلیل اکتشافی

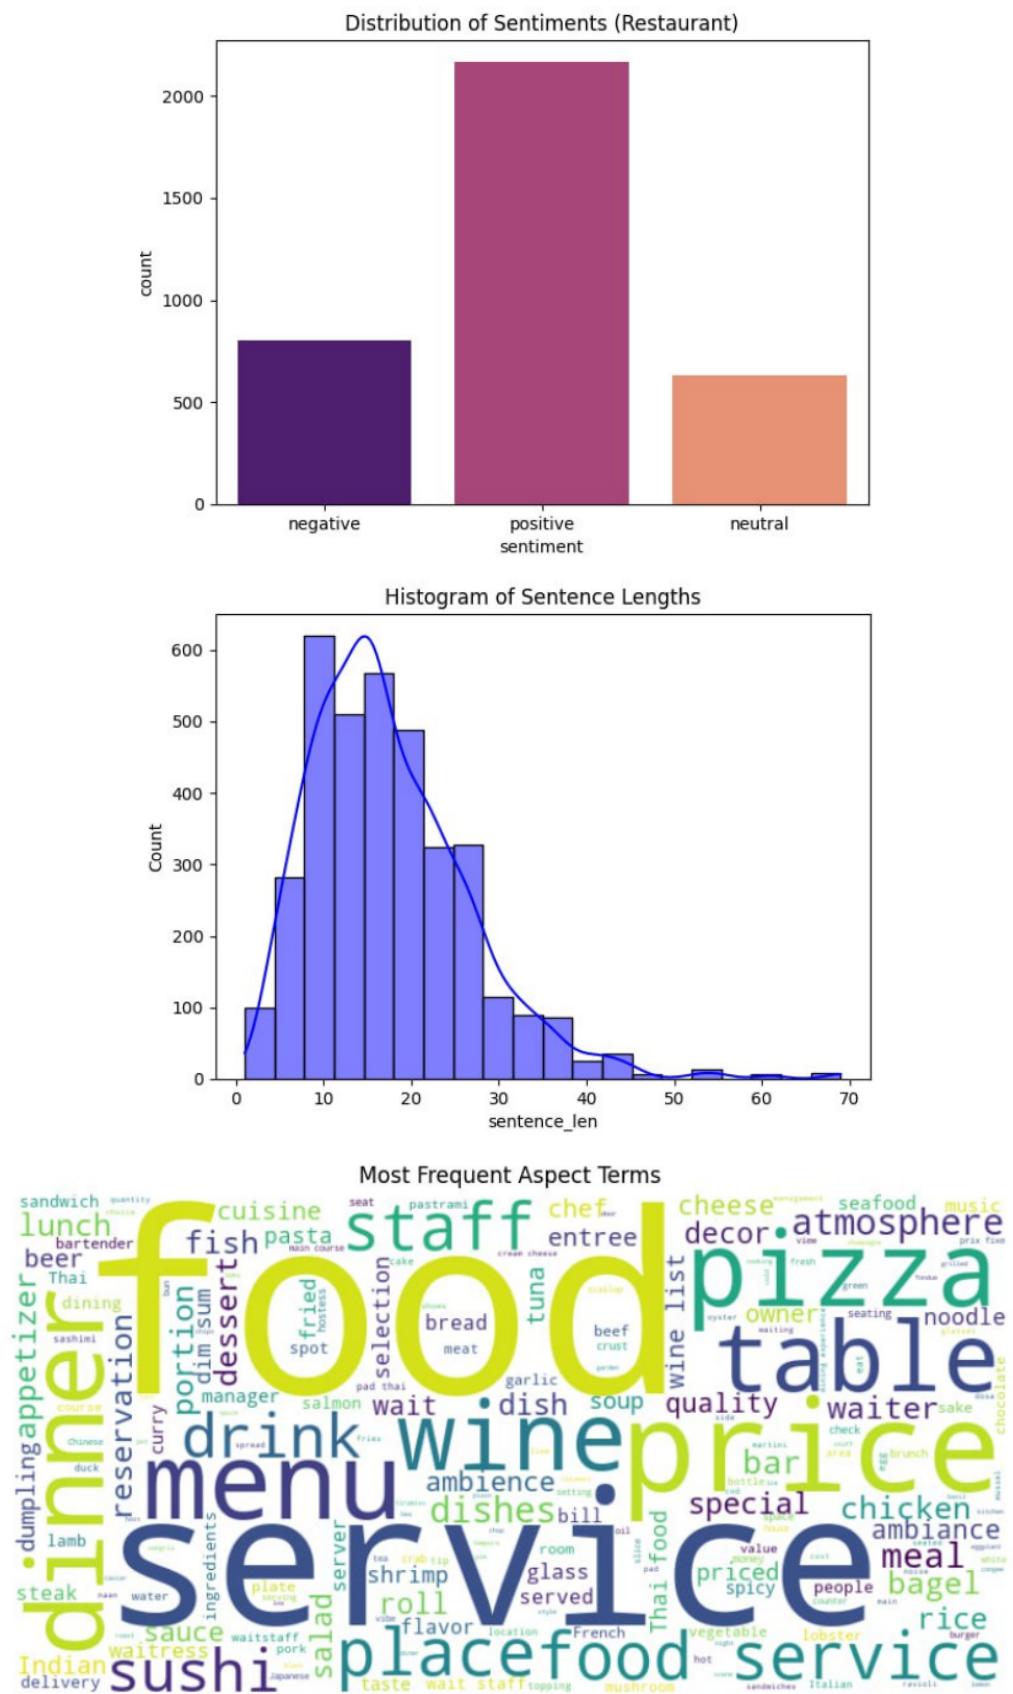
دریافت و استخراج داده:

داده های استاندارد (SemEval-2014 Task-4 Restaurant) از فایل XML خوانده شده اند. از آنجا که یک جمله ممکن است چند Aspect Term داشته باشد، در مرحله استخراج، به ازای هر جنبه یک رکورد جدا ساخته شده است تا هر نمونه دقیقاً یک زوج (text, aspect) و یک برچسب sentiment داشته باشد. همچنین برچسب های conflict حذف شده اند و فقط سه کلاس negative, positive، neutral نگه داشته می شوند. خروجی این مرحله یک فایل تمیز به نام restaurant_cleaned_data.csv است که ستون های اصلی آن شامل id، text، sentiment و aspect است.

تحلیل اکتشافی (EDA):

برای تحلیل داده و شناخت بهتر توزیع آن، سه نمودار زیر ساخته و در گزارش قرار داده شده اند:

- **توزیع کلاس ها:** این نمودار نشان می دهد که داده ها از نظر برچسب ها متوازن نیستند و معمولاً تعداد نمونه های مثبت بیشتر از منفی و خنثی است. این نکته در فاز آموزش مدل مهم است و به همین دلیل در آموزش از وزن دهی کلاسی در تابع هزینه استفاده شده است.
- **هیستوگرام طول جمله ها:** طول جمله ها بر حسب تعداد کلمات محاسبه شده است. توزیع طول جمله ها معمولاً یک بخش اصلی در طول های متوسط دارد و یک دنباله بلند برای جمله های طولانی تر دیده می شود. این نمودار کمک می کند مقدار max_len را منطقی انتخاب کنیم (در این پروژه max_len=128 انتخاب شده تا حتی جمله های طولانی هم بدون مشکل پردازش شوند).
- **ابرکلمات جنبه ها:** با قرار دادن تمام term aspect ها کنار هم، پرتکرارترین جنبه ها مشخص می شوند. خروجی نشان می دهد جنبه هایی مثل food، service، place، staff و موارد مشابه، سهم زیادی از داده را تشکیل می دهند و در عمل، تمرکز مجموعه داده بیشتر روی همین موضوعات است.



شكل ۱: (از بالا به پایین) توزیع کلاس ها، هیستوگرام طول جمله ها، و ابرکلمات Aspect Term ها

فاز دوم: طراحی و پیاده سازی مدل

مرحله ۱: پیش پردازش داده

در این مرحله یک پیش پردازش ساده برای آماده سازی متن انجام شده است و خروجی در فایل restaurant_preprocessed_final.csv ذخیره می شود. روند کار به این صورت است که داده تمیز مرحله قبل (restaurant_cleaned_data.csv) خوانده می شود و یک ستون جدید به نام processed_text تولید می گردد. این ستون با یکتابع پاکسازی ساخته می شود که مراحل زیر را انجام می دهد:

- تبدیل متن به حروف کوچک
 - حذف علائم نگارشی و کاراکترهای خاص با regex
 - توکنایز کردن متن با NLTK
 - حذف های انگلیسی stopword
 - اتصال توکن های باقی مانده و تولید یک رشته تمیز

هدف این مرحله کاهش نویز و ساده سازی متن برای استفاده در مدل های مختلف است. (در مرحله آموزش، RoBERTa علاوه بر این مرحله، یک پاکسازی سبک داخل کد آموزش هم انجام شده است که شامل unescape HTML، حذف تگ های HTML و یکسان سازی فاصله ها است).

مرحله ۲: آموزش مدل RoBERTa

در این مرحله، مدل roberta-base برای دسته بندی سه کلاسه (negative/neutral/positive) fine-tune شده است. روند آموزش به شکل خلاصه ولی دقیق به صورت زیر است:

خواندن داده و فیلتر برچسب ها:

فایل های train.csv و val.csv خوانده می شوند. سپس فقط نمونه هایی که داشته می شوند که برچسب آن ها یکی از سه حالت negative، positive یا neutral باشد و بقیه (مثل conflict) حذف می شوند. همچنین سطرهایی که sentiment یا aspect text یا sentiment خالی باشد حذف می شوند.

ساخت ورودی مدل و توکنایز:

ورودی مدل شامل جمله و کلمه جنبه است، بنابراین tokenizer به صورت ورودی دوتایی استفاده می‌شود:

(text, aspect)

توکنایز با `max_len=128` و `truncation="only_first"` انجام می‌شود (یعنی اگر نیاز به کوتاه کردن باشد، جمله کوتاه می‌شود). در استفاده token_type_ids از RoBERTa از `Dataset` همان ابتدای ساخت انجام شده است تا در طول آموزش، فشار محاسباتی روی `getitem` کمتر باشد.

ساخت `batch` و `padding` به صورت `dynamic`:

در DataLoader از یک collate_fn استفاده شده است که با tokenizer.pad padding را به صورت پویا انجام می‌دهد. یعنی طول دنباله‌ها در هر batch برابر با بیشینه طول همان batch می‌شود و فقط input_ids و attention_mask ساخته می‌شود. همچنین برای تکرارپذیری، seed تنظیم شده و برای worker‌های DataLoader هم مقداردهی جدا انجام شده است.

مدل و تابع هزینه:

مدل RobertaForSequenceClassification با num_labels=3 استفاده شده است. برای کاهش اثر نامتوازن بودن کلاس‌ها، وزن های کلاسی از روی فراوانی برچسب‌های آموزش محاسبه شده و در CrossEntropyLoss استفاده می‌شود (وزن کلاس‌ها به صورت معکوس تعداد نمونه های همان کلاس است).

بھینہ سازی و زمان بندی نرخ پادگیری:

در آموزش اولیه، از AdamW با $\text{weight_decay}=0.01$ استفاده شده است. پارامترهای bias و weight از LayerNorm. weight decay معاف هستند. نرخ یادگیری $lr=2e-5$ است و زمان بندی آن با linear decay و سپس warmup انجام می‌شود. تعداد کل گام‌ها بر این $\text{len}(\text{train_loader}) * \text{epochs}$ است و نسبت $\text{warmup_ratio}=0.1$ در نظر گرفته شده است.

ساعت آموزشی و سایداری:

آموزش با mixed precision gradient clipping انجام شده است (GradScaler و torch.amp.autocast). همچنین با مقدار $\text{clip}=1.0$ اعمال می‌شود تا از انفجار گادیان جلوگیری شود.

ازیام، انتخاب مدل و خروجی ها:

در هر epoch، معیارهای loss، accuracy و macro-F1 محاسبه می‌شوند. معیار اصلی، پرای انتخاب بهترین

مدل val macro-F1 است. اگر بهبود رخ دهد وزن های مدل در best_model.pt ذخیره می شود. همچنین early stopping با validation patience=3 فعال است و اگر بهبود متوالی رخ ندهد آموزش متوقف می شود. در پایان، بهترین مدل بارگذاری می شود و روی confusion matrix چاپ می گردد. تاریخچه آموزش در train_history.csv و classification report f1.png acc.png loss.png برای بررسی روند آموزش ساخته و در پوشه خروجی ذخیره می شوند.

تنظیمات اولیه اجرای آموزش (مقادیر پیش فرض کد):

```
model_name=roberta-base •
max_len=128 •
batch_size=16 •
epoches=5 •
lr=2e-5 •
weight_decay=0.01 •
warmup_ratio=0.1 •
grad_clip=1.0 •
patience=3 •
num_workers=4 •
seed=42 •
output_dir=absa_output •
```

هاiperپارامترها و نقش آن ها در آموزش در fine-tuning مدل های زبانی مثل RoBERTa چند هایپرپارامتر اصلی داریم که مستقیماً روی سرعت همگرایی، پایداری آموزش و میزان overfitting اثر می گذارند. از آنجا که مدل با چند تنظیم مختلف آموزش داده شده است، در این بخش فقط نقش هر هایپرپارامتر توضیح داده می شود و مقادیر دقیق و نتایج آن ها (برای هر تنظیم) گزارش می شود.

(lr): Learning Rate • یادگیری سریع تر می شود ولی می تواند نوسان ایجاد کند یا باعث شود مدل از بهینه عبور کند. مقدار کوچک تر آموزش را پایدارتر می کند اما ممکن است همگرایی را کند کند یا مدل در یک نقطه نه چندان خوب متوقف شود. در fine-tuning معمولاً نرخ یادگیری حساس ترین هایپرپارامتر است.

overfitting • نوعی منظم سازی است که از بزرگ شدن بیش از حد وزن ها جلوگیری می کند و معمولاً به کاهش کمک می کند. ایده اصلی این است که مدل از راه حل های خیلی پیچیده که فقط داده های آموزش را حفظ می کنند فاصله بگیرد. در مدل های transformer weight decay bias و LayerNorm را از weight decay می کنند چون اعمال آن روی این پارامترها می تواند اثر منفی روی پایداری آموزش داشته باشد.

Warmup Ratio • در ابتدای آموزش اگر نرخ یادگیری از همان ابتدا بزرگ باشد، مخصوصاً در مدل های از پیش آموزش دیده، ممکن است گرادیان ها ناپایدار شوند. warmup باعث می شود نرخ یادگیری در چند درصد اول گام در صد خطی از مقدار کوچک به مقدار اصلی برسد و بعد وارد روند اصلی زمان بندی شود (مثلاً کاهش خطی). warmup ratio تعیین می کند چه سهمی از کل گام ها صرف این مرحله شود.

grad clip): Gradient Clipping • برای جلوگیری از انفجار گرادیان، نرم گرادیان ها محدود می شود. این کار باعث می شود گام های بروزرسانی خیلی بزرگ نشوند و آموزش پایدارتر شود. معمولاً در fine-tuning و مخصوصاً هنگام استفاده از mixed precision این تنظیم کمک می کند که آموزش از کنترل خارج نشود.

Patience • این پارامتر مربوط به early stopping است و مشخص می کند اگر معیار انتخاب مدل روی validation (مثلاً macro-F1) برای چند epoch پشت سر هم بهتر نشود، آموزش متوقف شود. هدف این است که آموزش بی دلیل ادامه پیدا نکند و مدل وارد overfitting نشود. مقدار کمتر باعث توقف سریع تر و مقدار بیشتر باعث فرصت بیشتر برای بهبود می شود.

(1 Run) تنظیمات هایپرپارامترها

مقادیر هایپرپارامترها:

```

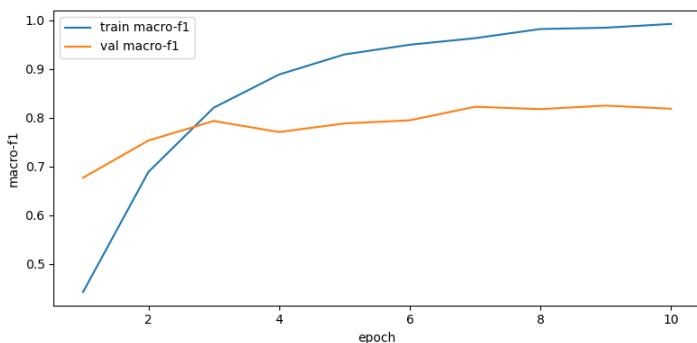
roberta-base :model_name ●
128 :max_len ●
16 :batch_size ●
10 :epochs ●
2e-5 :lr ●
005.0 :weight_decay ●
1.0 :warmup_ratio ●
0.1 :grad_clip ●
3 :patience ●
2 :num_workers ●
42 :seed ●

```

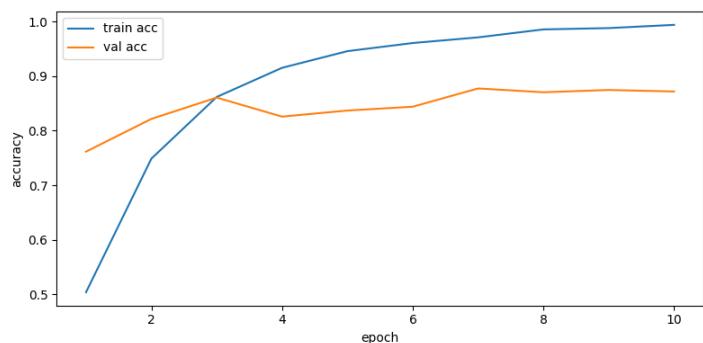
نتیجه نهایی روی validation

در پایان آموزش، بهترین مدل روی validation ارزیابی شده و مقادیر زیر گزارش شده است:

$$\text{Loss Val} = 1.0614, \quad \text{Acc Val} = 0.8745, \quad \text{Macro-F1 Val} = 0.8248.$$



(ب) نمودار validation و train برای macro-F1



(الف) نمودار validation و train برای accuracy

```

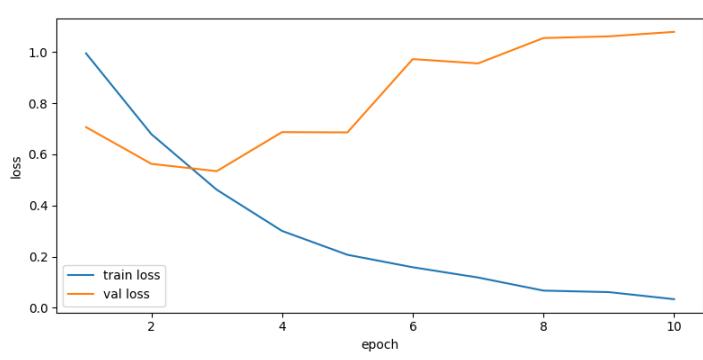
== Final Evaluation on Validation Set ==
Val Loss: 1.0614 | Val Acc: 0.8745 | Val Macro-F1: 0.8248

Classification Report:
precision    recall    f1-score   support
neg          0.87     0.84     0.85      162
neu          0.65     0.74     0.69      111
pos          0.94     0.92     0.93      444
accuracy           0.87      717
macro avg       0.82     0.83     0.82      717
weighted avg    0.88     0.87     0.88      717

Confusion Matrix:
[[136  21   5]
 [ 10  82  19]
 [ 11  24 409]]

```

(ت) classification report و confusion matrix



(پ) validation و train loss برای loss

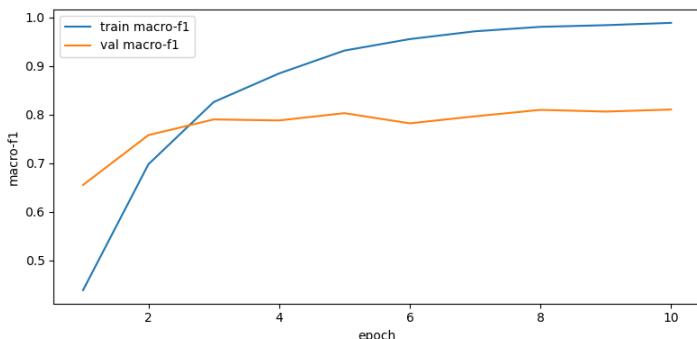
شکل ۲: خروجی های آموزشی و ارزیابی برای تنظیم هایپرپارامتر 1 Run

(2 Run) تنظیمات هایپرپارامترها
مقادیر هایپرپارامترها:

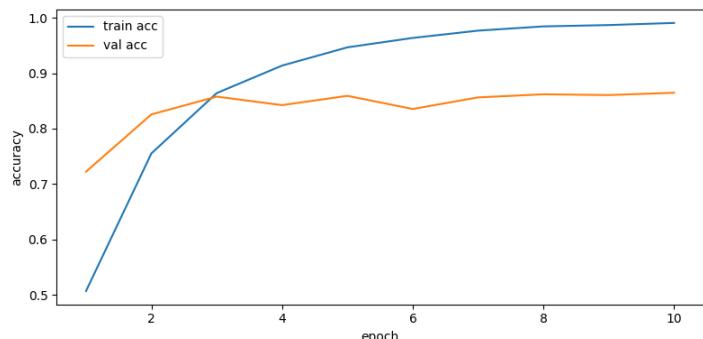
- 168 :max_len
- 16 :batch_size
- 10 :epochs
- 2e-5 :lr
- 02.0 :weight_decay
- 1.0 :warmup_ratio
- 0.1 :grad_clip
- 3 :patience

نتیجه نهایی روی validation
در پایان آموزش، بهترین checkpoint همین Run روی validation ارزیابی شده و مقادیر زیر گزارش شده است:

Loss Val = 1.1942, Acc Val = 0.8647, Macro-F1 Val = 0.8103.



(ب) نمودار validation و train برای macro-F1



(الف) نمودار validation و train برای accuracy

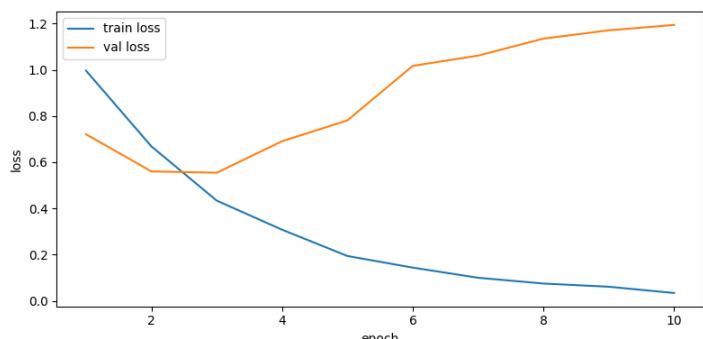
```
== Final Evaluation on Validation Set ==
Val Loss: 1.1942 | Val Acc: 0.8647 | Val Macro-F1: 0.8103

Classification Report:
precision    recall    f1-score   support
neg          0.82     0.85     0.83     162
neu          0.65     0.69     0.67     111
pos          0.94     0.91     0.93     444

accuracy           0.86      717
macro avg       0.80     0.82     0.81     717
weighted avg    0.87     0.86     0.87     717

Confusion Matrix:
[[137 18  7]
 [ 16 77 18]
 [ 15 23 406]]
Saved history to train.history.csv
Plots saved to absa_output
```

(ت) confusion matrix و classification report



(پ) نمودار validation و train برای loss

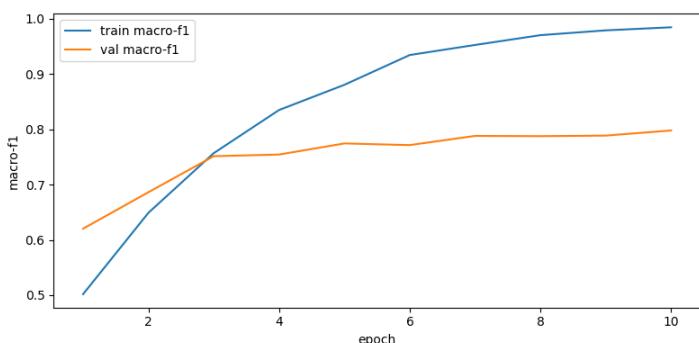
شکل ۳: خروجی های آموزشی و ارزیابی برای تنظیمات هایپرپارامتر 2 Run

(3 Run) تنظیمات هایپرپارامترها:
مقادیر هایپرپارامترها:

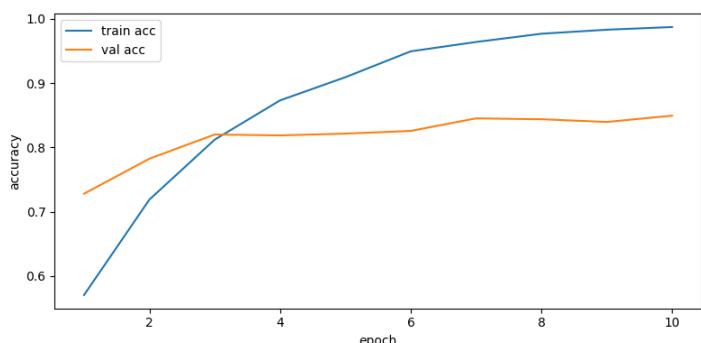
- 128 :max_len ●
- 8 :batch_size ●
- 10 :epochs ●
- 5e-5 :lr ●
- 01.0 :weight_decay ●
- 1.0 :warmup_ratio ●
- 0.1 :grad_clip ●
- 3 :patience ●

نتیجه نهایی روی validation
در پایان آموزش، بهترین checkpoint همین Run روی validation ارزیابی شده و مقادیر زیر گزارش شده است:

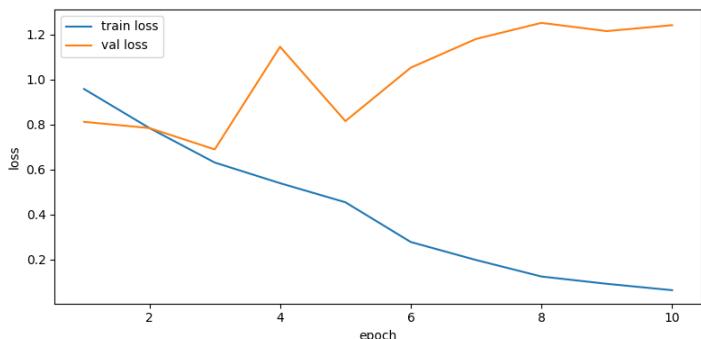
$$\text{Loss Val} = 1.2422, \quad \text{Acc Val} = 0.8494, \quad \text{Macro-F1 Val} = 0.7978.$$



(ب) نمودار validation و train برای macro-F1



(الف) نمودار validation و train برای accuracy



(پ) نمودار validation و train برای loss

confusion matrix و classification report (ت)

شکل ۴: خروجی های آموزشی و ارزیابی برای تنظیمات هایپرپارامتر 3 Run

(4 Run) تنظیمات هایپرپارامترها

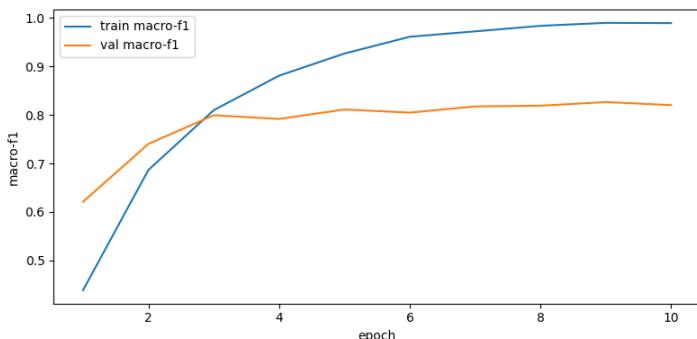
مقادیر هایپرپارامترها:

- 128 :max_len
- 16 :batch_size
- 10 :epochs
- 2e-5 :lr
- 0.001.0 :weight_decay
- 1.0 :warmup_ratio
- 0.1 :grad_clip
- 3 :patience

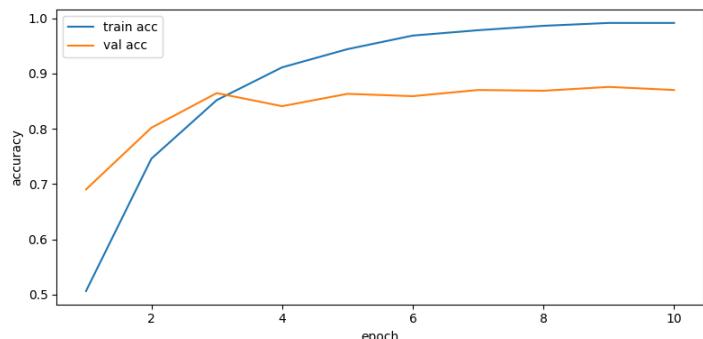
نتیجه نهایی روی validation

در پایان آموزش، بهترین checkpoint همین Run را ارزیابی شده و مقادیر زیر گزارش شده است:

$$\text{Loss Val} = 1.0727, \quad \text{Acc Val} = 0.8759, \quad \text{Macro-F1 Val} = 0.8266.$$



(ب) نمودار validation و train برای macro-F1



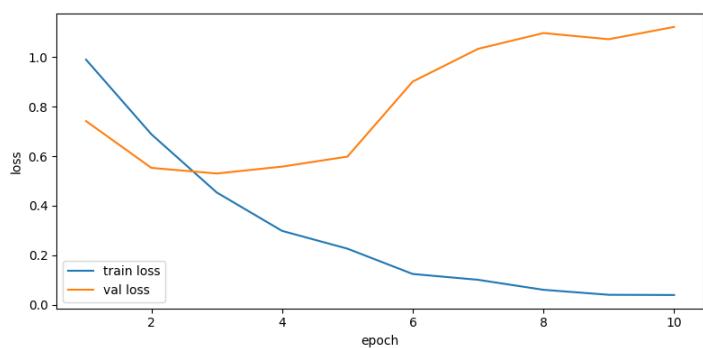
(الف) نمودار validation و train برای accuracy

```
*** Final Evaluation on Validation Set ***
Val Loss: 1.0727 | Val Acc: 0.8759 | Val Macro-F1: 0.8266

Classification Report:
precision    recall    f1-score   support
neg          0.86      0.88      0.87     162
neu          0.66      0.70      0.68     111
pos          0.94      0.92      0.93     444
accuracy           0.82      0.83      0.83     717
macro avg       0.82      0.83      0.83     717
weighted avg    0.88      0.88      0.88     717

Confusion Matrix:
[[143 13 6]
 [ 14 78 19]
 [ 10 27 407]]
```

(ت) classification report و confusion matrix



(ب) نمودار validation و train برای loss

شکل ۵: خروجی های آموزشی و ارزیابی برای تنظیم هایپرپارامتر 4 Run

(5 Run) تنظیمات هایپرپارامترها

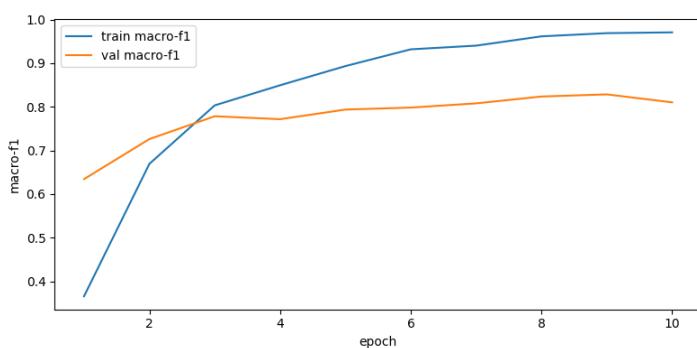
مقادیر هایپرپارامترها:

- 128 :max_len
- 16 :batch_size
- 10 :epochs
- 1e-5 :lr
- 0003.0 :weight_decay
- 1.0 :warmup_ratio
- 0.1 :grad_clip
- 3 :patience

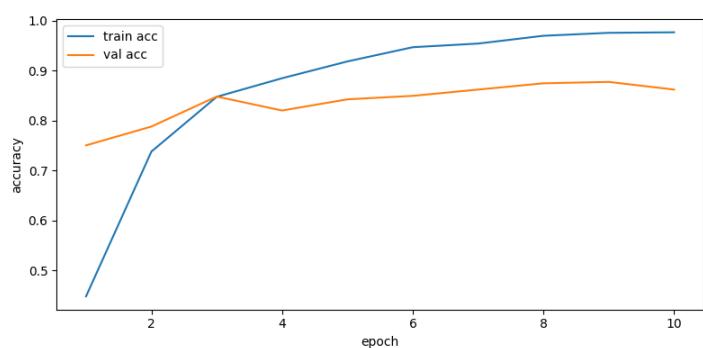
نتیجه نهایی روی validation
در پایان آموزش، بهترین checkpoint همین Run را ارزیابی شده و مقادیر زیر گزارش شده است:

$$\text{Loss Val} = 0.8183, \quad \text{Acc Val} = 0.8773, \quad \text{Macro-F1 Val} = 0.8285.$$

این Run در بین 5 تنظیم اجرا شده، بهترین نتیجه را (بر اساس Macro-F1) داشته است.



(ب) نمودار validation و train برای macro-F1



(الف) نمودار validation و train برای accuracy

```
== Final Evaluation on Validation Set ==
...
Val Loss: 0.8183 | Val Acc: 0.8773 | Val Macro-F1: 0.8285
```

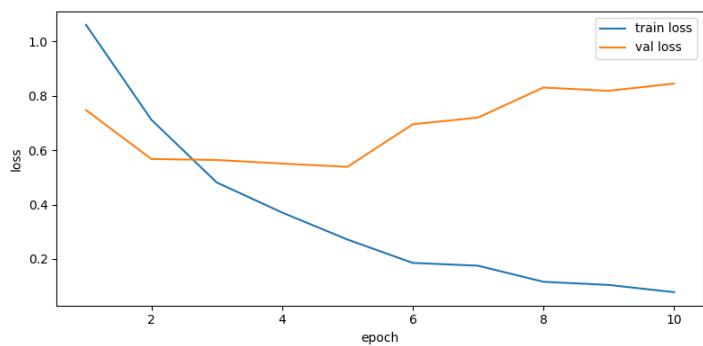
Classification Report:

	precision	recall	f1-score	support
neg	0.85	0.88	0.86	162
neu	0.67	0.71	0.69	111
pos	0.95	0.92	0.93	444
accuracy			0.88	717
macro avg	0.82	0.84	0.83	717
weighted avg	0.88	0.88	0.88	717

Confusion Matrix:

[143 14 5]
[14 79 18]
[12 25 407]]

(ت) confusion matrix و classification report



(پ) نمودار validation و train برای loss

شکل ۶: خروجی های آموزشی و ارزیابی برای تنظیمات هایپرپارامتر 5 Run (بهترین نتیجه)

فاز سوم: ارزیابی و تحلیل خطا

در این فاز، مدل نهایی (بهترین تنظیم های پارامتر) روی داده های ارزیابی اجرا شده و معیارهای Precision، Recall و F1-Score Macro-F1 گزارش شده اند. همچنین برای تحلیل رفتار مدل، ماتریس آشفتگی رسم شده و ۵ نمونه از خطاهای مدل بررسی شده است.

نتایج کلی (براساس ماتریس آشفتگی)
با استفاده از ماتریس آشفتگی زیر، دقت کلی مدل برابر با

$$\text{Accuracy} = 0.8705$$

$$\text{Macro-F1} = 0.8002$$

به دست آمده است. معیارهای هر کلاس نیز به صورت زیر است:

F1	Recall	Precision	کلاس
8325.0	8367.0	8283.0	negative
6350.0	5459.0	7589.0	neutral
9331.0	9670.0	9014.0	positive

طبق جدول بالا، عملکرد مدل روی کلاس positive بهتر از بقیه است و بیشترین ضعف مدل مربوط به کلاس neutral است (به خصوص Recall پایین تر).

ماتریس آشفتگی و نمونه خطاهای

تحلیل خطا (۵ نمونه)

در ادامه، ۵ نمونه خطا که در خروجی مدل گزارش شده اند آورده شده و دلیل احتمالی خطا به صورت کوتاه بیان شده است:

• نمونه ۱:

Text: The portions of the food that came out were mediocre.
Aspect: portions of the food True: neutral Pred: negative

واژه هایی مثل mediocre بار منفی دارند و مدل به طور طبیعی آن را منفی برداشت می کند، در حالی که برچسب داده به صورت خنثی ثبت شده است. این نوع ابهام برچسب گذاری معمولاً باعث کاهش Recall کلاس neutral می شود.

• نمونه ۲:

Text: How pretentious and inappropriate for MJ Grill to claim that it provides power lunch and dinners!

Aspect: lunch True: negative Pred: positive

ساختر جمله حالت کنایه دارد و ممکن است مدل به علت وجود عبارت های عمومی مثل power lunch یا الگوی جمله، برداشت اشتباه مثبت داشته باشد.

• نمونه ۳:

Text: How pretentious and inappropriate for MJ Grill to claim that it provides power lunch and dinners!

Aspect: dinners True: negative Pred: neutral

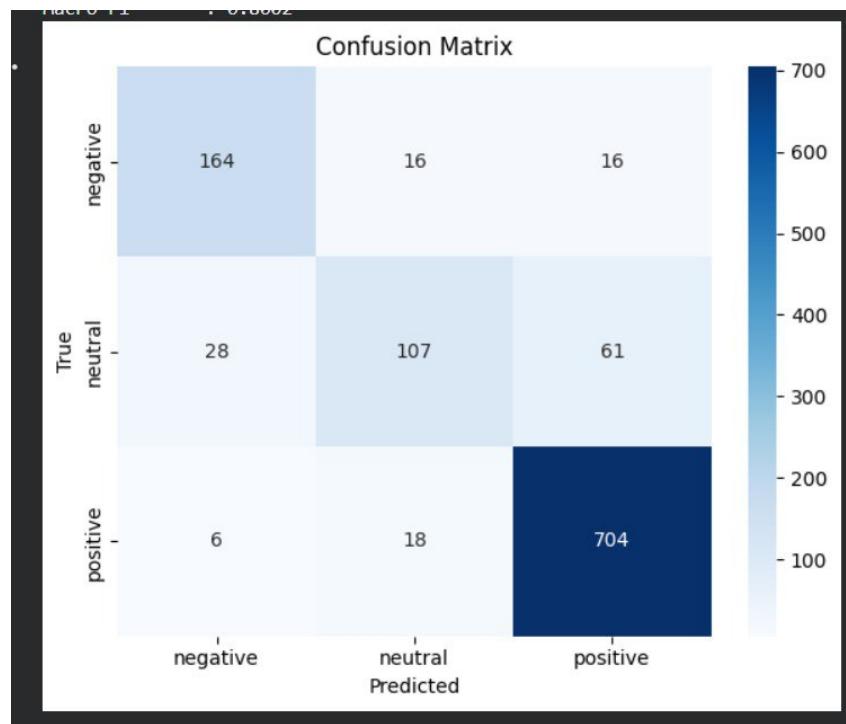
در این نمونه، مدل منفی بودن کلی جمله را به صورت کامل روی جنبه dinners منتقل نکرده و آن را خنثی دیده است. این نوع خطأ معمولاً وقتی رخ می دهد که جمله بیشتر حالت کلی داشته باشد و اتصال مستقیم به جنبه ضعیف باشد.

• نمونه ۴:

Text: Entrees include classics like lasagna, fettuccine Alfredo and chicken parmigiana.

Aspect: Entrees True: neutral Pred: positive

ذکر اسم غذاها و ساختار معروفی منو می تواند توسط مدل به عنوان نشانه مثبت برداشت شود، در حالی که جمله واقعاً فقط توصیفی است و احساس مشخصی ندارد.



... == 5 Misclassified Examples ==

```

Text      : The portions of the food that came out were mediocre.
Aspect    : portions of the food
True      : neutral
Pred      : negative
-----
Text      : How pretentious and inappropriate for MJ Grill to claim that it provides power lunch and dinners!
Aspect    : lunch
True      : negative
Pred      : positive
-----
Text      : How pretentious and inappropriate for MJ Grill to claim that it provides power lunch and dinners!
Aspect    : dinners
True      : negative
Pred      : neutral
-----
Text      : Entrees include classics like lasagna, fettuccine Alfredo and chicken parmigiana.
Aspect    : Entrees
True      : neutral
Pred      : positive
-----
Text      : Entrees include classics like lasagna, fettuccine Alfredo and chicken parmigiana.
Aspect    : lasagna
True      : neutral
Pred      : positive

```

شکل ۷: (بالا) ماتریس آشتفتگی مدل نهایی (پایین) ۵ نمونه از خطاهای مدل

• نمونه ۵:

Text: Entrees include classics like lasagna, fettuccine Alfredo and chicken parmigiana.

Aspect: lasagna True: neutral Pred: positive

مشابه نمونه قبل، مدل روی نام غذا حساس است و آن را به سمت مثبت می‌برد، در حالی که این جمله صرفاً معرفی منو است.

فاز چهارم: تست مدل و بررسی استحکام (Robustness)

1) تست جمله‌های چالش برانگیز (20 جمله)

در این بخش، خروجی مدل برای 20 جمله چالش برانگیز به صورت اسکرین شات‌های زیر در گزارش قرار داده شده است.

Enter your sentence (or type 'exit'):

> the food was not fatty

Enter aspect:

> food

Prediction: positive

Probabilities:

Negative: 0.0026

Neutral : 0.1692

Positive: 0.8282

Enter your sentence (or type 'exit'):

> The restuarant was not bad at all but not best choice for next time.

Enter aspect:

> restuarant

Prediction: negative

Probabilities:

Negative: 0.9760

Neutral : 0.0015

Positive: 0.0225

Enter your sentence (or type 'exit'):

> If the service is always this slow, I won't return

Enter aspect:

> service

Prediction: negative

Probabilities:

Negative: 0.9983

Neutral : 0.0005

Positive: 0.0012

Enter your sentence (or type 'exit'):

> this restuarant has also same quality with other restuarant

Enter aspect:

> restaurants

Prediction: positive

Probabilities:

Negative: 0.0007

Neutral : 0.0005

Positive: 0.9987

> The burger would be better if it was not oily.

Enter aspect:

> burger

Prediction: negative

Probabilities:

Negative: 0.9982

Neutral : 0.0007

Positive: 0.0011

Enter your sentence (or type 'exit'):

> The coffee is bitter unless you add sugar.

Enter aspect:

> coffee

Prediction: negative

Probabilities:

Negative: 0.9981

Neutral : 0.0007

Positive: 0.0012

Enter your sentence (or type 'exit'):

> If I were you ; absoulutely choice pizza

Enter aspect:

> pizza

Prediction: positive

Probabilities:

Negative: 0.0008

Neutral : 0.0006

Positive: 0.9986

Prediction: negative

Probabilities:

Negative: 0.9978

Neutral : 0.0008

Positive: 0.0014

> If they don't have fish, I will eat chicken.

Enter aspect:

> fish

Prediction: negative

Probabilities:

Negative: 0.9938

Neutral : 0.0055

Positive: 0.0007

Enter your sentence (or type 'exit'):

> rice wasnt salty at all

Enter aspect:

> rice

Prediction: positive

Probabilities:

Negative: 0.0107

Neutral : 0.0012

Positive: 0.9881

Enter your sentence (or type 'exit'):
 > If you love spicy food, this curry is for you.
 Enter aspect:
 > curry

Prediction: positive
 Probabilities:
 Negative: 0.0006
 Neutral : 0.0007
 Positive: 0.9987

Enter your sentence (or type 'exit'):
 > Even if it is cheap, the quality should be better.
 Enter aspect:
 > quality

Prediction: negative
 Probabilities:
 Negative: 0.9977
 Neutral : 0.0007
 Positive: 0.0015

Enter your sentence (or type 'exit'):
 > Unless you book a table, you will have to wait
 Enter aspect:
 > wait

Prediction: negative
 Probabilities:
 Negative: 0.9980
 Neutral : 0.0010
 Positive: 0.0009

Enter your sentence (or type 'exit'):
 > I would only come back if this were the last restaurant on Earth
 Enter aspect:
 > restaurant

Prediction: positive
 Probabilities:
 Negative: 0.0450
 Neutral : 0.0366
 Positive: 0.9183

Enter your sentence (or type 'exit'):
 > If you haven't tried their rice yet, you haven't lived
 Enter aspect:
 > rice

Prediction: positive
 Probabilities:
 Negative: 0.0128
 Neutral : 0.0299
 Positive: 0.9573

Enter your sentence (or type 'exit'):
 > The fish is fresh if that is what you want.
 Enter aspect:
 > fish

Prediction: positive
 Probabilities:
 Negative: 0.0005
 Neutral : 0.0012
 Positive: 0.9983

Enter your sentence (or type 'exit'):
 > Don't eat the salad if you have allergies.
 Enter aspect:
 > salad

Prediction: negative
 Probabilities:
 Negative: 0.9982
 Neutral : 0.0006
 Positive: 0.0012

Enter your sentence (or type 'exit'):
 > If you sit by the window, you can see the street
 Enter aspect:
 > window

Prediction: positive
 Probabilities:
 Negative: 0.0088
 Neutral : 0.0418
 Positive: 0.9494

Enter your sentence (or type 'exit'):
 > If I wanted frozen food, I would have stayed at home
 Enter aspect:
 > frozen

Prediction: negative
 Probabilities:
 Negative: 0.9863
 Neutral : 0.0128
 Positive: 0.0009

Enter your sentence (or type 'exit'):
 > That mixed pizza would be the last choice for me
 Enter aspect:
 > pizza

Prediction: negative
 Probabilities:
 Negative: 0.9509
 Neutral : 0.0474
 Positive: 0.0017

حمله تخاصمی ساده

در این بخش یک جمله‌ای انتخاب شد که مدل آن را درست دسته بندی می‌کند، سپس با یک تغییر جزئی (بدون تغییر معنی اصلی از نظر انسان) تلاش شد مدل به اشتباه بیفتند. در مثال زیر، اضافه شدن کلمه like باعث تغییر برچسب پیش‌بینی شده شده است.

در جمله اول، مدل برچسب neutral را پیش‌بینی کرده است، اما با اضافه کردن like در جمله دوم، خروجی مدل به positive تغییر کرده است. دلیل احتمالی این خطای این است که مدل در برخی موارد وجود کلمه like را به عنوان سیگنال مثبت در نظر می‌گیرد، در حالی که در این جمله like به معنی «مشابه» است و بار احساسی مثبت ندارد.

Enter your sentence (or type 'exit'):

> this resturant was casual

Enter aspect:

> restaurants

Prediction: neutral

Probabilities:

Negative: 0.0009

Neutral : 0.9521

Positive: 0.0470

Enter your sentence (or type 'exit'):

> this restaurants was casual like others

Enter aspect:

> restaurants

Prediction: positive

Probabilities:

Negative: 0.0006

Neutral : 0.0017

Positive: 0.9978

Enter your sentence (or type 'exit'):

>

شکل ۸: نمونه حمله تخاصمی ساده با اضافه شدن کلمه like